

KB-08 — Evaluation

متریک‌های مالی / held-out test set، eval-driven (نه vibes-shipping)، چارچوب سنجش WP-E. eval-harness + guardrails + anomaly alert، (خام pass-rate نه) **Wilson lower-bound** با A/B، قیف alert.

۰. خلاصه سریع

نه **cost-per-booked-job (AUD)** = هیچ قابلیت بدون رد آزمونی منتشر نمی‌شود. متریک شمال مالی استفاده می‌شود تا با نمونه کوچک گول نخوریم Wilson کران پایین A/B، برای مقایسه cost-per-lead. ورودی/خروجی + هشدار آنومالی (هزینه/کنش خارج از محدوده) فعال اند guardrails.

۱. هدف

کیفیت/هزینه/انطباق regression تصمیم محصول روی داده واقعی، نه حدس؛ و جلوگیری از

۲. متریک‌ها

متریک	تعریف	منبع
cost-per-lead (AUD)	lead / هزینه کل	KB-02 + KB-06 COST_EVENT
cost-per-booked-job (AUD)	booked job / هزینه کل	متریک حاکم
funnel	enquiry→quote→job rate	KB-09
review rate	review درخواست→ثبت	KB-09/03
suburb-page rank	local رتبه	KB-13
queue reject-rate	rejected / submitted	KB-05
gate block-rate	hard-block / drafts	KB-07

۳. A/B با Wilson lower-bound

Wilson خام، بلکه کران پایینِ بازه اطمینانِ pass-rate نه، (follow-up مثل دو) variant برای مقایسه دو. برای نرخ موفقیت ملاک است؛ این با نمونه کوچک محافظه کارانه تر و پایدارتر است.

```
flowchart LR
    A["variant A: n_A, success_A"] --> WA["Wilson lower-bound A"]
    B["variant B: n_B, success_B"] --> WB["Wilson lower-bound B"]
    WA --> CMP{"بالاتر؟ کدام LB"}
    WB --> CMP
    CMP --> WIN["برنده (با اطمینان، نه شانس)"]
```

این را تنبیه می‌کند. Wilson پایین دارد؛ LB، ی که با کمترین نمونه «شانسی» جلو افتاده variant: منطق (محاسبه = تعریف ریاضی؛ بدون کد در این سند).

۴. eval حلقه

```
flowchart TD
    G["Generator (content/lead tool)"] --> H["held-out test set"]
    H --> E["Evaluator (rubric + guardrails)"]
    E -->|fail| G
    E -->|pass| GATE["Constitution Gate (KB-07)"]
    GATE --> M["متریکها (AUD, funnel, Wilson)"]
    M --> DEC["تصمیم محصول (Operator)"]
    M -.anomaly.-> AL["alert: از محدوده کنش خارج"]
```

۵. ابزار (alt / lock-in)

eval-harness: promptfoo / DeepEval / Braintrust! guardrails: NeMo Guardrails / Guardrails AI.
interface مشترک → lock-in عمدتاً توکن CONFIG cap (در run کم. هزینه: عمدتاً توکن lock-in → مشترک interface).

۶. نگاهشِ حاکمیتی (۷ اصل)

budget → eval هزینه! HITL → Operator تصمیم! observability → anomaly alert! tool-gateway → eval روی های tool scoped! no-SPOF → held-out از train! counter-leverage → Wilson به جای cherry-pick! eval = ۷ اصل خود.

۷. قواعد سخت

= خام. ۳. متریک حاکم pass-rate نه، Wilson lb با A/B اجباری. ۲. held-out! no vibes-shipping! ۱.

cost-per-booked-job. ۴. anomaly → alert، نه ادامه خاموش

۸. قدم بعدی

CONFIG. DoD:  Wilson
بدون کد  guardrails،  تعریف شده،  متریک مالی وصل