

فیوژن در دنیای واقعی — چکلیست پیاده‌سازی با مولتی‌ایجنت ۲۰۲۶

اصل ترجمه: «قوانین» فیوژن = کنترل‌های حاکمیتی. پیاده‌سازی قوانین یعنی پیاده‌سازی بودجه، نظارت، شفافیت و چک‌وبالانس. **خارج از حوزه (خلاف قانون مبنا):** ساخت ایجنتی که هویت انسان را جعل کند، از نظارت بگریزد، یا در برابر خاموشی مقاومت کند. این قوانین دقیقاً جلوی همین‌ها را می‌گیرند.

۱) متابولیسم → بودجه و حسابداری منابع

هر کنش هزینه دارد و ثبت می‌شود (لاند/وئر).

- در ارکستریاتور rate-limit + برای توکن/محاسبه/هزینه؛ سقف سخت per-agent بودجه‌ی
- که هر فراخوان ابزار/مدل را متر و لاگ می‌کند cost-accounting لایه‌ی
- قطع خودکار وقتی ایجنت از بودجه‌اش عبور کرد (LangGraph/AutoGen/Agents SDK + budget hooks)

۲) مالکیت گرادیان → کنترل انسانی و کلید قطع

صاحب منبع، صاحب کنترل است.

- برای کنش‌های پرخطر (مالی، نوشتن خارجی، تغییر حالت) HITL approval gate
- kill-switch/halt (circuit breaker) که هر ایجنت یا کل سیستم را آنی متوقف کند
- که اجازه‌ها را قبل از اجرا صادر می‌کند (supervisor) ایجنت ناظر

۳) شفافیت مکث → رصد، ممیزی، مکث و بازرسی

حالت باید قابل بازرسی باشد.

- پذیر replay! tool-call! کامل استدلال + هر tracing (Langfuse/LangSmith/Arize Phoenix, OpenTelemetry-GenAI)
- سیستم در آستانه‌ها مکث کند تا انسان حالت را ببیند: «pause & inspect» حالت
- غیرقابل دستکاری برای همه‌ی کنش‌های بیرونی audit log

گذرگاه ابزار + least-privilege → دسترسِ مقید (۴)

هیچ کنش بی‌ردپا و بی‌مجوز

- عبور کند scoped سیاست‌دار با مجوزِ tool-gateway هر کنش خارجی از یک (MCP + policy layer, scoped API keys)
- نه دسترسیِ خام، (container/microVM) جدا sandbox اجرای کد/فایل در
- (no anonymous reach) انتسابِ روشن: هر کنش ایجنت به کاربر/منشأش گره بخورد

بدون نقطه‌ی تصرفِ واحد → تنوع و تفکیک (۵)

هیچ ایجنت/انسانی نقطه‌ی شکستِ واحد نباشد

- separation of duties صفر نظارتِ بالا + نظارتِ صفر
- بین ایجنت‌ها؛ هیچ‌کدام هم‌زمان توانِ بالا + نظارتِ صفر
- !. پرهیز از تک‌نقطه‌ی تصمیم‌provider چند ناظر/چند

قیدِ متقابل → تقسیم نقش و چک‌وبالانس (۶)

هر طرف /هرمی واقعی نگه دارد

- با نقش‌های تخصصی جدا که هم را راستی‌آزمایی می‌کنند supervisor/worker الگوی
- override اجباری در آستانه escalation انسانی همیشه بالاتر از تصمیم ایجنت؛
- بالا فقط با نظارتِ متناظر مجاز capability: خودمختاریِ کراندار

مانیتورینگ، شبیه‌سازیِ شکست eval، آزمون‌پذیری (۷)

هیچ توان/نفوذی بدون ردپای پرداختنی: null

- eval-harness + خودکار برای رفتار guardrails. (promptfoo/DeepEval/Braintrust)
- مانیتورِ آنومالی: هشدار اگر نفوذ/کنش از هزینه/مجوزِ خوانا گسسته شد
- guardrails سیاستی روی ورودی/خروجی (NeMo Guardrails/Guardrails AI)

رصد + (MCP + policy) ابزار + (LangGraph/AutoGen/Agents SDK) استکِ ۲۰۲۶ (نمونه): ارکستریاتور (Langfuse/Phoenix/OTel) + گاردریل (NeMo/Guardrails AI) + sandbox + HITL gates.

supervisor + kill- گاردریل کدنویسی کن. (۲) + system policy سه قدم اول: (۱) قانون‌مبنا را به‌صورت کامل را روشن کن — قبل از هر خودمختاریِ tracing/audit را بساز. (۳) switch + HITL gate

