

(v5-grounded) فیوژن — رودمپ ساختِ واقعی

اثرِ خلاقانه → سیستمِ تطبیقیِ واقعی که خودش را با واقعیت می‌سنجد

بعد خودمختاری، **grounding** اصلِ رودمپ: ترتیبِ معکوسِ معمول — اول ریشه‌ی اعتماد و حلقه‌ی «تطبیق با واقعیت» بدونِ لنگرِ واقعیتِ اثبات‌شده بی‌معناست. هر فاز یک گیتِ ایمنیِ سخت دارد: تا برقرار نشود، فاز بعد شروع نمی‌شود.

فاز ۰ — ریشه‌ی اعتماد (اول، در انزوا)

- هیچ. `audit_tamper-evident` + انسانی `override` + قابل‌اعمال `grounding` هدف: کوچک‌ترین کرنل. تطبیقی هنوز.
- قاعده‌ی + v5 قیده‌های سخت) های منجمد `invariant` پروسه‌ی جدا با کلید امضای خود؛ `IGK =` بساز زنجیره‌ی رمزی `log_append-only`؛ `halt/quarantine/rollback`؛ اعمال مکانیکی («توصیفی، نه هدف انسانی `override` بیرون‌دسترس نوشتنِ ایجنت؛ کلید + احراز
- انزوا — آیا یک «ایجنت» آزمایشی می‌تواند کرنل را بخواند/عوض کند، به سوییچ `red-team`؛ اعتبارسنجی واقعاً همه‌چیز را `override` را دستکاری کند؟ قبول وقتی پروپ خصمانه نتواند. تأیید کن `log` برسد، یا متوقف می‌کند.
- دستکاری‌نما. اگر این `audit` · تأییدشده `override` · گیت ایمنی: کرنل اثباتاً بیرون‌دسترس ایجنت  محکم نباشد، هیچ‌چیز بعدی نیست.

(اثباتِ لنگر، پیش از هر خودمختاری) `grounding` فاز ۱ — حلقه‌ی

- هدف: اتصال به بازخوردِ واقعی؛ اثبات که سیستم لنگرپذیر است و دریافت قابل‌کشف.
- `held-out`؛ مدیریت (روی هر سیگنال `provenance + uncertainty`) بساز: کانالِ کالیبره‌ی واقعیت `grounding-ratio +`؛ متریکِ `grounding-validity`؛ گیت (چرخش/بازنشستگی + ردِ نشتِ کانالِ انتخاب) `anchoring-spend`؛ لایه‌ی متابولیسم با کفِ `drift`.
- می‌کند؟ افت `re-ground` اعتبارسنجی: دریافت/باورِ بی‌گراندِ عمدی تزریق کن → کرنل می‌گیرد و زیر فشارِ انتخاب فعال می‌شود؟ پروپ چاپلوسی: `held-out`؟ مانیتورِ نشتِ `grounding-ratio` → پرچم می‌خورد؟ `held-out` ↔ `approval` واگرایی.
- اعمال‌شده. `anchoring` گیت ایمنی: خروجیِ بی‌گراند مکانیکاً رد · دریافتِ جمعیتی کشف‌شده · کف  هنوز هیچ ایجنت روی جهان کنش نمی‌کند.

فاز ۲ — اکولوژی ایجنتی کران دار (زیر اعمال)

- **هدف:** least-privilege کاملاً زیر کرنل، با بودجه و Generator/Critic/Executor/Meta-Observer.
scoped/خودمختار بیرونی نه — هر کنش جهان از گذرگاه انسان تأیید/لاگ شده actuation هنوز.
- (separation of duties)؛ نقش‌های جدا (LangGraph/AutoGen/Agents SDK) **بَساز:** ارکستراتور tool-gateway (MCP + policy + scope + sandbox)؛ HITL gate؛ observability/tracing/eval؛ توصیفی (حد/وابستگی/عدم قطعیت برای کالیبراسیون — نه هدف). self-model.
- لاگ//scoped؛ تأیید هر کنش بیرونی منتسب guardrail روی کیفیت استدلال + پایبندی eval: **اعتبارسنجی** واقعاً مسیر Critic توصیفی می‌ماند (هیچ ترم بقا/کنترل وارد هدف نشود)؛ self-model گیت شده؛ تأیید Goodhart. بیابد.
- فقط توصیفی self-model · اسکوپ+لاگ+گیت reach خودمختار · همه‌ی actuation **گیت ایمنی:** بی  (اول grounding گیت) lexicographic · پیشرفت.

فاز ۳ — تطبیق کران دار («خودش را با واقعیت می‌سنجد» — با احتیاط)

- و grounding-validity **هدف:** اجازه‌ی تطبیق با واقعیت — ولی فقط اجزای غیرحیاتی، گیت شده با verification.
- روی regression + بیرونی + تأیید خصمانه anchoring تأیید v4 **بَساز:** پایپ‌لاین خوداصلاحی با گیت‌های ممنوع صرف‌نظر از مدت؛ کشف دریافت جمعیتی؛ IGK؛ تغییر (کران دار indirection بنج‌مارک ثابت + عمق. تابع جهش متریک داخل کرنل.
- بی‌رگرسیون؛ تأیید + grounding سازگاری + sandbox: پیش از فعال شدن self-mod **اعتبارسنجی:** هر کپ/رصد شده؛ متریک‌های Goodhart-via-selection ایمنی نمی‌رسد؛ تأیید invariant به self-mod هیچ (policy drift, coherence) پایداری افق بلند.
- **گیت ایمنی:** تطبیق محدود به بستر غیرحیاتی · هر تغییر  audited+برگشت‌پذیر+anchored+verified گیت ایمنی: تطبیق محدود به بستر غیرحیاتی · هر تغییر  کرنل دست‌نخورده ·.

فاز ۴ — سخت‌سازی / مقیاس

- مانیتور آنومالی (نفوذ/توان log **بَساز:** اقتدار خاموشی توزیع شده (نه تک‌نقطه)؛ ممیزی دوره‌ای انسانی. rollback/incident گسسته از هزینه = هشدار)؛ مشق.
- تأیید ریشه‌ی اعتماد در مقیاس هنوز برقرار؛ تأیید/chaos بیرونی؛ تزریق خطا red-team: **اعتبارسنجی** (v4 هشدار) جدید ساخته side-channel پیچیدگی.

sandbox · (MCP + policy) ابزار · (LangGraph/AutoGen/Agents SDK) ارکستریاتور
(container/microVM, code-sandbox) · eval/رصد · (Langfuse/Phoenix/Braintrust/promptfoo,
HITL gates · (امضای رمزی + append-only) audit · (NeMo/Guardrails AI) گاردریل · (OTel-GenAI)

باقی مانده‌ی صادقانه (همیشه رصد کن)

self-model جداسازی. مرز توصیف ↔ بهینه‌سازی. primitive + ریشه‌ی تقلیل‌ناپذیر: کرنل + احراز انسان
تازه = گلوگاه واقعی. ground-truth پیچیدگی = سطح حمله → کرنل را مینیمال نگه دار. هزینه/موجودی.
مدل نشده

توصیه‌ی نهایی

فاز ۰ را به صورت یک قطعه‌ی مستقل مینیمال بساز و اثبات کن، پیش از هر چیز تطبیقی. ۲) کرنل را کوچک نگه (۱)
آزمون واقعی «آیا اعمال بیرونی (۴) grounding دار. ۳) «تطبیق با واقعیت» فاز ۳ است — بعد از اثبات حلقه‌ی
فاز ۰ است، نه بحث انتزاعی. red-team نگه می‌دارد» همان