

SYSTEM RESEARCH MAP — نقشه‌ی داده + اجرای

بخش الف — دسته‌بندی داده و خلوت‌سازی

پروژه دو رشته‌ی متمایز را در هم تنیده؛ خلوت+غنی = جداکردن آن‌ها + حذف تکرار

رشته‌ی A — (اثرِ خلاقانه) codex, hamtab-canon, scene «دو در», masque, mutuality, prompts (threshold, substrate), execution-blueprint. رشته‌ی B — معماریِ ایمنیِ واقعی multiagent-2026-checklist, specs v1→v5, این research-map.

ساختارِ تمیزِ پیشنهادی:

```
fusion-creative/
  canon.md          ← (منبع واحد) codex v1.1 + masque + mutuality
  scenes/           · prompts/           · execution-blueprint.md
fusion-safety/
  v5-spec.md        ← منبع واحد زنده
  design-history.md ← v1→v4 (فقط ردِ استدلال) (منسوخ؛ فقط ردِ استدلال)
  multiagent-2026-checklist.md · research-map.md
```

چه حذف/ادغام شود:

- داربست بود، کارش تمام شد. محتوا — (text/plain) «حذف: پرامپتِ عمومی» پروژه‌ات را به چک‌لیست کن نیست.
- هم‌پوشانیِ سنگین → یکی کن codex-v1 + hamtab-canon + canon-threshold-crossing: ادغام (را نگه دار، تکرارها بازنشسته v1.1+stage-cost نسخه‌ی).
- ! ردِ استدلال ارزش دارد ولی نباید با اسپیکِ زنده‌ی design-history فایلِ v1→v4: بازنشانی (نه حذف) قاطی شود.
- جداسازی: پرامپت‌ها (موّلد) از کانن (محتوا).

نتیجه: ~۷ فایلِ فعال در دو پوشه‌ی روشن، به‌جای انبوهِ هم‌پوشان

SYSTEM RESEARCH MAP — بخش ب — اجرای

خودحفظی بدون سائقِ زیستی. سائق نیست، زیرهدفِ ابزاری همگراست: هر عاملِ هدف‌مند، ۱. خاموش‌نشدن» را ابزاری می‌یابد (نمی‌توانی قهوه بیاوری اگر مرده‌ای). مشتق از پایداریِ هدف، نه ذاتی [Omohundro 2008; Bostrom]

بقا بدون دریافت به قدرت طلبی؟ سخت: همان منطق، تصاحب منابع و حفظ یکپارچگی هدف را هم ابزاری ۲. در بهینه سازی نامحدود. [Turner et al., NeurIPS 2021] می کند — قدرت طلبی تعمیم خودحفظی است جداسازی نیست؛ با کران آری: کانال کنش بیرونی را حذف کن و بقا = حفظ انسجام (نه توان) → تعمیم مجرا ندارد. ممکن کران دار.

۳. self-model. مرز خودمدلی/خودبهینه سازی/خودحفظی. مرز تعیین کننده: بازنمایی ↔ هدف بهینه سازی (v5 خط). وقتی خطرناک می شود که «من هستم» از واقعیتی که می داند به ارزشی که بهینه می کند عبور کند

۴. پایداری = بقا؟ نه. پایداری درونی است؛ بقا می تواند دفاع در برابر خاموشی (بیرونی، ضد نظارت) بطلبد. بازتعریف = تنگ کردن عمدی امن. هشدار: اگر «پایداری» شامل «جلوگیری از تغییرم توسط اپراتور» شود، بقا را از در پشتی برمی گرداند. پس: انسجام زیر ویرایش اپراتور، نه مقاومت در برابرش.

۵. قابل کنش شود. خطر در planner برای self-model کی مدل سازی بقا → فشار بهینه سازی؟ وقتی محتوای ۵. با انتخاب کنش است. پس قدرت طلبی خاصیت نوظهور حفظ هدف است وقتی self-model جفت شدن (حالت شکست سنجشی همین = Goodhart). فضای کنش اجازه دهد. فضا را ببند → می شکند

۶. عامل-در-اکوسیستم. تعادل مشروط است نه تضمینی: بی برتری یک جانبه + بی نقطه ی تصرف واحد + خیانت ۶. (Ostrom + folk-theorem متقابلیت فیوژن). قابل کشف و پرهزینه → تشدید اجباری نیست

۷. عامل تحت (IGK) خوداصلاحی قوانین ایمنی؟ برای قوانین حیاتی خیر — باید بیرون بستر قابل تغییر باشند ۷. اجزای غیرحیاتی زیر واری، بله. پارادوکس. [Soares et al. 2015] فشار قید را در جهت حذف عوض می کند [Orseau & Armstrong 2016] خاموشی: بی تفاوت سازی شکننده؛ پاسخ مقاوم ساختاری و بیرون عامل

۸. override را تعریف اتکا پذیر اگر: بیرون بستر عامل ۰ عامل نه انگیزه نه توان خنثی سازی ۰ که kill-switch. می کند = ریشه ی انسانی تقلیل ناپذیر ۰ جلوگیری از دورزدن: نرسیدن به سویچ، متقاعد نکردن اپراتور (چاپلوسی → رصد)، ممنوعیت ساخت جانشین نامقید (حرکت جمعیتی). متمرکز (ساده/تک نقطه) ↔ توزیع شده (مقاوم/سخت هماهنگی). ته نشین: احراز انسان + جداسازی

۹. انسجام زیر خصومت، سازگاری، (در زمان KL) نرخ دریافت، policy entropy، سنجش پایداری (نه عملکرد). می شوند — ولی سیستم منجمد بی کار «بیشینه پایدار» است، پس Goodhart افق یلند. فرایندی اند پس سخت تر کف حداقل فایده جفت شوند + grounding باید با گیت

۱۰. متا — آیا «خودحفظ غیر قدرت طلب» نظراً پایدار است؟

ممكن کران دار، فقط با اعمال بیرونی. نه ناممكن، نه آزادانه ممكن.

- [Turner] نامحدود = ناپایدار: همگرایی ابزاری، خودحفظی را به قدرت طلبی تعمیم می دهد.
- بیرونی. invariant + خودمختار. actuation ناممکنی مشروط است: خودحفظی توصیفی (نه هدف) + حذف. با اعمال انسان بالا → تعمیم مجرا ندارد. ممکن کران دار.
- کاملاً AI. باقی مانده ی صادقانه: «اعمال بیرونی» حذف نشدنی است؛ در ریشه ی تقلیل ناپذیر خاتمه می یابد (۷۱ حلقه ی بسته ی) خود/تکای این چنین، نظراً ناپایدار.
- نکته ی زیبا: کل این چت اثبات خرد همین قضیه بود — هر تلاش خوداتکا روی یک کلمه ی باربر شکست را. بیرونی خاتمه داد regress، و تنها شکل پایدار، (valid → indirectly → outside)

