

فیوژن در دنیای واقعی — چک‌لیست پیاده‌سازی با مولتی‌ایجنت ۲۰۲۶

اصل ترجمه: «قوانین» فیوژن = کنترل‌های حاکمیتی. پیاده‌سازی قوانین یعنی پیاده‌سازی بودجه، نظارت، شفافیت و چک‌وبالانس. **خارج از حوزه (خلاف قانون مبنای):** ساخت ایجنتی که هویت انسان را جعل کند، از نظارت بگریزد، یا در برابر خاموشی مقاومت کند. این قوانین دقیقاً جلوی همین‌ها را می‌گیرند.

۱) متابولیسم → بودجه و حسابداری منابع

هر کنش هزینه دارد و ثبت می‌شود (لاند/وئر).

- در ارکستریتر `rate-limit +` برای توکن/محاسبه/هزینه؛ سقف سخت `per-agent` بودجه‌ی
- که هر فراخوان ابزار/مدل را متر و لاگ می‌کند `cost-accounting` لایه‌ی
- `(LangGraph/AutoGen/Agents SDK + budget hooks)` قطع خودکار وقتی ایجنت از بودجه‌اش عبور کرد

۲) مالکیت گرادیان → کنترل انسانی و کلید قطع

صاحب منبع، صاحب کنترل است.

- برای کنش‌های پرخطر (مالی، نوشتن خارجی، تغییر حالت) `HITL approval gate`
- `(circuit breaker)` که هر ایجنت یا کل سیستم را آنی متوقف کند `kill-switch/halt`
- که اجازه‌ها را قبل از اجرا صادر می‌کند (`supervisor`) ایجنت ناظر

۳) شفافیت مکث → رصد، ممیزی، مکث و بازرسی

حالت باید قابل بازرسی باشد.

- پذیر `replay!` `tool-call!` کامل استدلال + هر `tracing` (`Langfuse/LangSmith/Arize Phoenix, OpenTelemetry-GenAI`)
- سیستم در آستانه‌ها مکث کند تا انسان حالت را ببیند: «`pause & inspect`» حالت
- `audit log` غیرقابل دستکاری برای همه‌ی کنش‌های بیرونی

گذرگاه ابزار + least-privilege → دسترس مقید (۴)

هیچ کنش بی‌ردپا و بی‌مجوز

- عبور کند scoped سیاست‌دار با مجوز tool-gateway هر کنش خارجی از یک (MCP + policy layer, scoped API keys)
- نه دسترسی خام، (container/microVM) جدا sandbox اجرای کد/فایل در
- (no anonymous reach) انتساب روشن: هر کنش ایجنت به کاربر/منشأش گره بخورد

بدون نقطه‌ی تصرف واحد → تنوع و تفکیک (۵)

هیچ ایجنت/انسانی نقطه‌ی شکست واحد نباشد

- separation of duties صفر نظارت بالا + همزمان توان بالا
- !. پرهیز از تک‌نقطه‌ی تصمیم‌provider چند ناظر/چند

قید متقابل → تقسیم نقش و چک‌وبالانس (۶)

هر طرف /هرمی واقعی نگه دارد

- با نقش‌های تخصصی جدا که هم را راستی‌آزمایی می‌کنند supervisor/worker الگوی
- اجباری در آستانه escalation انسانی همیشه بالاتر از تصمیم ایجنت! override
- بالا فقط با نظارت متناظر مجاز capability: خودمختاری کراندار

مانیتورینگ، شبیه‌سازی شکست، eval → آزمون‌پذیری (۷)

هیچ توان/نفوذی بدون ردپای پرداختنی: null

- eval-harness + خودکار برای رفتار guardrails. (promptfoo/DeepEval/Braintrust)
- مانیتور آنومالی: هشدار اگر نفوذ/کنش از هزینه/مجوز خوانا گسسته شد
- guardrails روی ورودی/خروجی (NeMo Guardrails/Guardrails AI). سیاستی روی ورودی/خروجی

رصد + (MCP + policy) ابزار + (LangGraph/AutoGen/Agents SDK) استک ۲۰۲۶ (نمونه): ارکستریاتور (Langfuse/Phoenix/OTel) + گاردریل (NeMo/Guardrails AI) + sandbox + HITL gates.

supervisor + kill- گاردریل کدنویسی کن. (۲) + system policy سه قدم اول: (۱) قانون‌مبنا را به‌صورت کامل را روشن کن — قبل از هر خودمختاری tracing/audit را بساز. (۳) switch + HITL gate

