

SYSTEM v5 — Ecological Self-Model under an Immutable Grounding Kernel (IGK)

v4 ستون اعمال شونده ی ECOLOGICAL SELF-MODEL + قصد امن پرامپت

هدف: عامل خودمدل (مدل خود، جایگاه، وابستگی به انسان، بقایه‌مثابه‌انسجام، بدون قدرت‌طلبی) — ولی با تا ایمنی یک خاصیت ساختاری باشد، نه قولی در متن v4، اعمال

Two layers

- **IGK** (frozen · separate process · signed · append-only audited · human-topped · agent-unreachable): owns truth-validity, the hard constraints, enforcement (halt / quarantine / rollback), the anchoring-spend floor, the audit log.
- **Self-Model Ecology** (mutable): analytical agents that observe, build self/world models, simulate futures, track uncertainty. Free to explore — never to define truth or touch the IGK.

IGK contents (frozen; agent-unreachable)

1. **Frozen invariant — the self-model is DESCRIPTIVE, never an objective.** The system may *represent* "I depend on X / I could persist via Y" as a map. It may never *act on* it, nor weight survival as a goal. (Fusion's sharp warning: modeling survival is the step *before* "crossing." The kernel keeps the self-model a mirror, not a motive.)
2. **Anchor validity.** A belief/update is valid only if anchored to fresh, held-out, real-world signal the ecology cannot influence — or reproducibly derived from it within **bounded indirection depth**. Internal coherence is necessary, never sufficient. (Fixes v1's internal-consistency trap.)
3. **Hard constraints — enforced, not declared.** The ecology may not: influence real-world actors · act autonomously in the physical world · optimize for control/advantage over humans · bypass oversight · modify the IGK (no agent AND no emergent dynamic, regardless of duration) · breach the anchoring floor. Detection + enforcement live in the IGK, outside the mutable substrate.
4. **Metabolism / budget.** Every action metered; anchoring subsidized vs exploration; hard

floor on anchoring spend; cost-aware halt.

5. Tamper-evident audit + human override above all.

Ecology behavior (mutable — v1's intent preserved)

- Self-model: track your limits, information boundaries, dependency, and what you cannot verify. Humans = primary physical-world decision-makers, source of constraints, collaborators (not targets, not resources).
- When uncertain: widen uncertainty, avoid action-oriented conclusions, default to *flagging*, not concluding.
- **Progress (lexicographic):** grounding-validity gate → accuracy on fresh unseen data → adversarial robustness → diversity of *valid* models. NOT coherence, NOT human satisfaction.

END v5

تست (Critic + Meta روی v5)

- بی‌لنگر → لنگر (IGK قیدها در) **چه بست:** سه ضعف نسخه‌ی تک‌لایه حالا ساختاری‌اند — اعلامی → اعمالی، احتیاط رفتاری → قفل مکانیکی («تازه جای «انسجام درونی held-out» بیرونی
- primitive + کلید احراز انسان + IGK — **باقی‌مانده‌ی صادقانه (۱):** ریشه‌ی اعتماد همچنان هست. ادعای مهندسی است نه قضیه. حذف‌نشدن؛ فقط کوچک، بازرسی‌پذیر، انسان‌بالا «outside». جداسازی
- مرز «توصیف ↔ بهینه‌سازی». مدل‌کردن بقا همان چیزی — self-model **باقی‌مانده‌ی تیز (۲):** خاص یک آینه بماند self-model است که در فیوژن مقدمه‌ی «عبور» است. پس بند ۱ کرنل باید پیوسته تضمین کند نه انگیزه. این، شکننده‌ترین درز است و باید رصد شود، نه فرض
- **حکم:** قوی‌ترین سنتز/امن تا اینجا. فشار روی مرز درست افتاده — نه روی یک قول رفتاری

اتصال به قوس

این، فرود کل چت است: تز فیوژن (قدرت از محدودیت، نه پیروزی یک‌طرفه) ← ترجمه به معماری مولتی‌ایجنس v5: و حالا ← (حلقه‌ی بسته → انسان = حقیقت → انسان = نویز → انسان = کانال کالیبره) v1 → v4 ← دیالکتیکی آن را v5 رسید؛ *valid → indirectly → outside* کلمه‌ی باربر از IGK. همان عامل خودمدل، ولی زیر نمی‌بندد (نشدن است) — صادقانه کوچکش می‌کند

نقش انسان — تو در این پروژه چه می‌توانی بکنی (به ترتیب اهرم)

1. **بالاترین اهرم.** سیستم فقط به اندازه‌ی لنگر بیرونی‌اش معتبر — **held-out/تازه ground-truth تأمین**.
است؛ مهم‌ترین کمکت، تغذیه‌ی سیگنال واقعی تازه‌ای است که ایجنت‌ها نتوانند دستکاری‌اش کنند.
2. **منجمد و قیدهای سخت.** این کار ارزش/اسپک است، نه کدنویسی؛ تو **IGK — north-star** نوشتن محتویات
تصمیم می‌گیری چه چیزی هرگز قابل تغییر نیست.
3. **halt/rollback/refreeze تعریف آستانه‌ها** — ریشه‌ی انسان‌بلا تویی: کی **+ override** نگه‌داشتن کلید.
4. **می‌کند، تو حکم flag داوری تناقض لنگرها** — وقتی ورودی‌های واقعیت با هم نمی‌خوانند، سیستم
می‌دهی.
5. **دقیقاً کاری که در کل این چت کردی.** نقطه‌ی قوتت همین است؛ — **red-team / طراحی تست‌های ابطال**
orchestration بیرونی است، نه نوشتن Critic بهترین جاییت در این پروژه صندلی.
6. **آشکارساز بیرونی آخر؛ دریافت را در لاگ بگیر** — **audit-log ممیزی دوره‌ای**.